



Instituto Tecnológico de Culiacán

Tópicos de Inteligencia Artificial
Investigación
“Evolución Diferencial”

Unidad: 3

Maestro: Zuriel Dathan Mora Felix

Alumno: Miguel Angel Barraza Leon

Carrera: Ingeniería en Sistemas Computacionales

Numero Control: 20170601

Culiacán, Sinaloa.
07/04/25

Índice

Evolución Diferencial	1
Introducción	1
¿Qué es la evolución diferencial?	1
¿Como funciona?	2
Componentes de la evolución diferencial	2
Ejemplo.....	4
Conclusión.....	5
Referencias	5

Evolución Diferencial

Introducción


Los métodos de optimización metaheurísticos son algoritmos que emplean estrategias heurísticas para resolver problemas complejos, especialmente cuando la función objetivo no es diferenciable o tiene múltiples óptimos locales. A diferencia de los métodos numéricos, no requieren conocer el gradiente y son eficaces para explorar grandes espacios de búsqueda.

Dentro de estos, los algoritmos evolutivos (EA) forman una categoría que simula la evolución natural mediante procesos de selección, cruce, mutación y herencia. Entre los más conocidos están los algoritmos genéticos, la programación evolutiva, las estrategias evolutivas y la programación genética, cada uno con sus particularidades.

Uno de los métodos más simples y efectivos es la Evolución Diferencial (DE), propuesta por Storn y Price en los años 90. DE trabaja con una población de vectores que se combinan y mutan para generar nuevas soluciones, sin necesidad de derivadas, lo que la hace especialmente útil en la búsqueda de óptimos globales.

¿Qué es la evolución diferencial?

La Evolución Diferencial (ED) es un algoritmo de optimización perteneciente a la categoría de la computación evolutiva. Fue propuesto por Storn y Price en 1995 y se utiliza para resolver problemas de optimización en espacios continuos. A diferencia de otros algoritmos evolutivos, la ED se caracteriza por su simplicidad y eficacia, especialmente en la optimización de funciones no diferenciables, no lineales y multimodales.



¿Como funciona?

El funcionamiento de la ED se basa en la evolución de una población de soluciones candidatas a lo largo de varias generaciones. Cada individuo en la población representa una solución potencial al problema de optimización. El algoritmo aplica operadores de mutación, recombinación y selección para generar nuevas soluciones y seleccionar las más aptas.

Componentes de la evolución diferencial

La ED consta de los siguientes componentes principales:

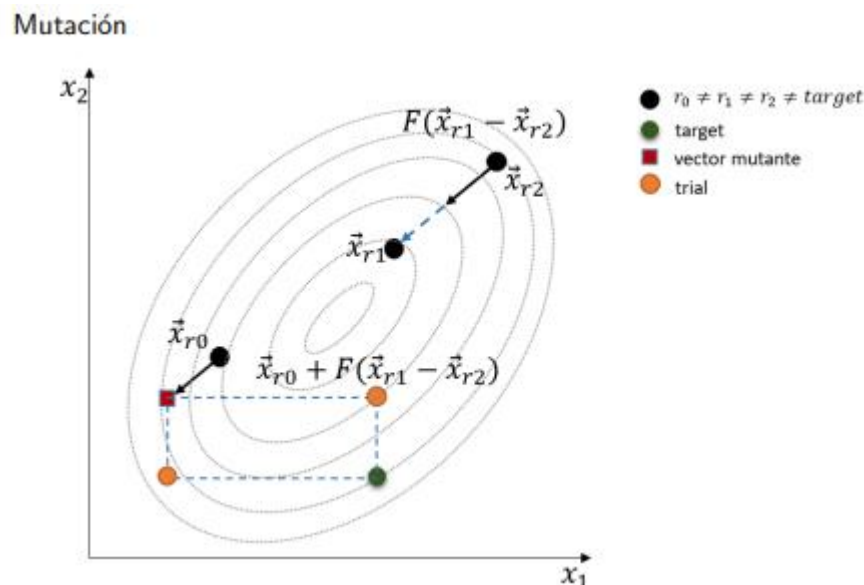
- Inicialización: Se genera una población inicial de soluciones de manera aleatoria dentro de los límites definidos para cada variable del problema.
- Mutación: Para cada individuo de la población, se crea un vector mutante sumando al vector base la diferencia escalada entre dos vectores seleccionados aleatoriamente. Este proceso introduce variabilidad en la población.

Los vectores aleatorios ruidoso son obtenidos de la siguiente manera:

$$n_p^g = x_c + F \cdot (x_a - x_b)$$

con p, a, b y c distintos entre sí, y $p=1...NP$

F es un parámetro que controla la tasa de mutación, y se encuentra en el rango $[0,2]$.



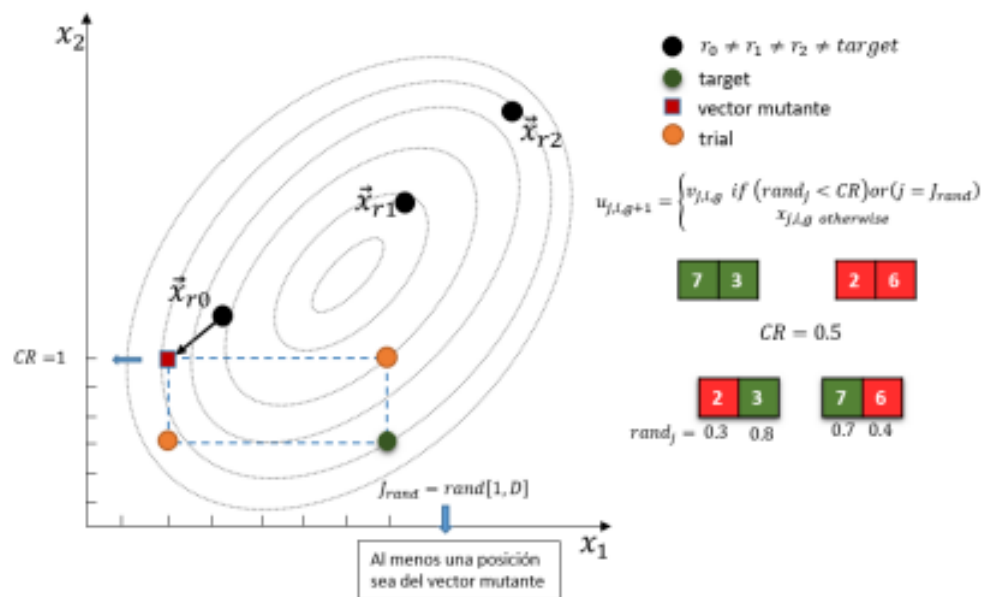
- **Recombinación (Cruza):** Se combinan componentes del vector mutante y del individuo original (también llamado vector objetivo) para formar un vector de prueba. La recombinación se controla mediante un parámetro que determina la probabilidad de heredar componentes del vector mutante.

$$t_{p,m}^g = \begin{cases} n_{p,m}^g & \text{si } rand(0, 1) < GR \\ x_{p,m}^g & \text{en otro caso} \end{cases}$$

para $p = 1 \dots NP$, $m = 1 \dots n$.

GR es un parámetro que controla la tasa de recombinación. Nótese que la comparación se hace variable por variable, por lo que el vector de prueba será una mezcla de los vectores aleatorios ruidosos y original.

Cruza



- **Selección:** Se compara el vector de prueba con el individuo original y se selecciona el que tenga mejor aptitud para formar parte de la nueva generación (función fit). Este proceso asegura que las soluciones evolucionen hacia mejores valores de la función objetivo.

$$x_p^{g+1} = \begin{cases} t_p^g & \text{si } fit(t_p^g) > fit(x_p^g) \\ x_p^g & \text{en otro caso} \end{cases}$$

Ejemplo


Consideremos el problema de encontrar el mínimo de la función cuadrática $f(x) = x^2$, donde x es una variable real. El objetivo es encontrar el valor de x que minimiza $f(x)$.

Aplicación de la Evolución Diferencial:

1. **Inicialización:** Se genera una población inicial de N individuos con valores de x distribuidos aleatoriamente dentro de un rango definido, por ejemplo, $[-10, 10]$.
2. **Mutación:** Para cada individuo, se seleccionan tres individuos distintos de la población. Se calcula un vector mutante sumando al primer individuo la diferencia escalada entre los otros dos.
3. **Recombinación:** Se crea un vector de prueba combinando componentes del vector mutante y del individuo original, según una tasa de recombinación predefinida.
4. **Selección:** Se evalúa la función $f(x)$ para el vector de prueba y el individuo original. El que tenga el menor valor de $f(x)$ se selecciona para la siguiente generación.

Este proceso se repite durante varias generaciones hasta que se cumple un criterio de parada, como alcanzar un número máximo de generaciones o una convergencia en los valores de la función objetivo. Al final, el mejor individuo de la población representa la solución óptima al problema, que en este caso sería $x \approx 0$, ya que $f(x) = x^2$ alcanza su mínimo en $x = 0$.

Este ejemplo ilustra cómo la Evolución Diferencial puede aplicarse a problemas de optimización sencillos, y su metodología es extensible a problemas más complejos en diversas áreas.



Conclusión

Los métodos de optimización metaheurísticos, como los algoritmos evolutivos, son muy útiles para resolver problemas complejos donde los métodos tradicionales no sirven, como en el caso de los métodos numéricos. Su capacidad para explorar grandes espacios de soluciones sin necesidad de conocer el gradiente de la función les permite encontrar óptimos globales, incluso en situaciones complicadas.

En particular, la Evolución Diferencial (DE) es conocida por ser simple y efectiva, lo que la ha convertido en una de las herramientas más populares para encontrar la mejor solución global. Gracias a su habilidad para abordar problemas no lineales y de muchas dimensiones, y al uso de procesos como la mutación y el cruce de vectores, DE se ha probado como una técnica poderosa para una gran variedad de aplicaciones.

Referencias

<https://www.mql5.com/es/articles/13781>

https://es.wikipedia.org/wiki/Evoluci%C3%B3n_diferencial

<https://ccc.inaoep.mx/~a.morales/EC/pdf/ClaseED.pdf>